1. Definicja zadania

- **Task:** Klasyfikacja tekstowa lub regresja na podstawie opisów fabuły filmów. Naszym celem jest przewidzenie, czy dany film odniesie sukces (np. wysoka ocena lub wysoki przychód) na podstawie samego opisu tekstowego.
- **Input:** Tekstowy opis filmu (kolumna overview ze zbioru TMDB).
- **Output:** Klasa (np. Sukces / Porażka) lub wartość ciągła (przewidywana ocena).

2. Wybrany model

- **Model name:** distilbert-base-uncased
- **Model type:** Encoder-only Transformer (rodzina BERT).

3. Uzasadnienie wyboru

- **Dlaczego ta architektura:** BERT (i DistilBERT) wykorzystuje mechanizm *Self-Attention*, który rozumie kontekst słów w zdaniu. W opisach filmów znaczenie ma nie tylko pojedyncze słowo, ale ich wzajemna relacja (np. "komedia romantyczna" vs "czarna komedia").
- **Dlaczego ten rozmiar:** DistilBERT jest o 40% mniejszy i 60% szybszy niż standardowy BERT, zachowując przy tym ok. 97% jego dokładności.

4. Zamierzone zastosowanie

- **Mapowanie do Pipeline:** Model zostanie użyty w potoku text-classification.
- **Dane wejściowe:** Surowy tekst opisu filmu z bazy danych, uprzednio stokenizowany.
- **Oczekiwane wyjście:** Prawdopodobieństwo przynależności do klasy sukcesu rynkowego.

5. Ograniczenia i ryzyka

- **Jakość danych:** Jeśli opis filmu jest bardzo krótki lub lakoniczny, model może mieć problem z poprawną analizą.
- **Uprzedzenia (Bias):** Model był trenowany na tekstach z internetu, więc może wykazywać uprzedzenia kulturowe lub gatunkowe (np. faworyzować kino akcji kosztem niszowych dramatów).

- **Długość tekstu:** Modele BERT mają limit 512 tokenów. Zbyt długie opisy będą ucinane.

6. Plan ewaluacji (Evaluation plan)

- Skuteczność modelu ocenimy za pomocą metryk:
  - **Accuracy:** Jaki procent filmów został przypisany do poprawnej kategorii.
  - **F1-Score:** Aby upewnić się, że model radzi sobie dobrze zarówno z hitami, jak i niszowymi filmami (szczególnie przy nierównowadze danych).
  - **Confusion Matrix:** Aby zobaczyć, które filmy model najczęściej myli.

7. Rozważane ograniczenia zasobów (Resource constraints considered)

- **Główne ograniczenia:** Limit pamięci RAM oraz dostępność jednostki GPU.
- **Sprzęt:** Model będzie uruchamiany na **GPU** (np. darmowe Tesla T4 w Google Colab). Uruchomienie na CPU byłoby możliwe, ale trening trwałby zbyt długo.
- **Czas trenowania:** Przewidywany czas fine-tuningu na zbiorze TMDB (po przefiltrowaniu) to ok. 15-30 minut.
- **Pamięć:** Rozmiar modelu to ok. 260 MB, co nie stanowi problemu dla nowoczesnych systemów.

8. Plan douczania (Fine-tuning plan)

- Planujemy zamrozić początkowe warstwy modelu i dotrenować tylko końcową głowicę klasyfikacyjną (classification head) na naszych specyficznych danych filmowych. Wykorzystamy bibliotekę Hugging Face Transformers.

9. Alternatywy (Alternatives)

- **BERT-base-uncased:** Rozważany, ale odrzucony ze względu na większe zapotrzebowanie na zasoby przy niewielkim wzroście dokładności.
- **RoBERTa:** Nowocześniejsza wersja BERT-a, rozważana jako opcja rezerwowa, jeśli DistilBERT nie osiągnie zadowalających wyników.
- **GPT-2:** Rozważany, ale odrzucony – modele typu Decoder (GPT) lepiej generują tekst, natomiast modele typu Encoder (BERT) lepiej go rozumieją i klasyfikują.